

Experimentos computacionais para predição da variação dimensional longitudinal

Este texto consolida a escrita dos nove experimentos computacionais associados ao sistema preditivo para análise da variação dimensional de concretos com macrofibras e aditivos compensadores de retração.

A sequência experimental foi organizada para partir da caracterização física da variável de resposta, avançar para a construção da base longitudinal, comparar formulações e modelos, analisar erros, testar atributos e consolidar um protótipo preditivo.

Experimento 1 — Caracterização da variação dimensional por idade

Síntese teórico-metodológica

O primeiro experimento teve caráter exploratório e descritivo. A finalidade foi caracterizar a distribuição da variação dimensional nas idades de 12 h, 1 dia, 3 dias, 7 dias, 14 dias, 28 dias e 56 dias, preservando o sinal da deformação. Essa decisão é importante porque a base apresentou valores positivos, negativos e nulos, correspondentes, respectivamente, a expansão, retração e estabilidade dimensional.

Esta decisão é sustentada por Khajehdehi et al. (2018) que analisam efeitos combinados de cura interna, SCMs e aditivos expansivos na retração do concreto, o que evidencia que o comportamento dimensional pode incluir mecanismos de compensação e expansão. Statkauskas et al. (2022) também discutem aditivos redutores de retração e fibras em composições cimentícias, reforçando que a resposta não se limita à contração final. Folorunsho et al. (2024) destacam a relevância das primeiras idades no controle de fissuras por retração plástica, o que justifica a análise temporal inicial.

Desta forma o experimento fornece a base conceitual do uso do termo “variação dimensional”. A análise descritiva também permite verificar a dispersão dos dados antes da modelagem, aspecto compatível com as preocupações de Taffese et al. (2025) sobre qualidade e heterogeneidade de bases em aplicações de machine learning à durabilidade do concreto.

Desenvolvimento detalhado do experimento

1. Caracterização e finalidade

Este experimento inaugura a sequência experimental, para avaliar a **variação dimensional longitudinal do concreto**. A finalidade é caracterizar o comportamento da variável de resposta nas idades de 12 h, 1 dia, 3 dias, 7 dias, 14 dias, 28 dias e 56 dias, preservando o sinal dos valores medidos.

A interpretação adotada é:

- valores negativos indicam **retração**;
- valores positivos indicam **expansão**;
- valores iguais a zero indicam **estabilidade dimensional**.

Esse experimento é essencial porque mostra que a variável de interesse deve ser tratada como **variação dimensional**, uma vez que a base contém registros positivos, negativos e nulos.

2. Base e variáveis analisadas

A base utilizada é a planilha **Análise retração_Guilherme.xlsx**, localizada na raiz do projeto. Foram consideradas as colunas de variação dimensional nas sete idades experimentais. Neste experimento ainda não há treinamento de modelo; a análise é descritiva.

3. Procedimento executado

O script carregou a base, padronizou os nomes das colunas, reorganizou as medidas por idade e calculou estatísticas descritivas e contagens de sinais. Também foram gerados gráficos para comparação temporal da média e da distribuição dos valores.

Tabela 1 — Estatísticas da variação dimensional por idade

A Tabela 1 resume a variação dimensional em cada idade. Ela apresenta número de registros, média, mediana, desvio-padrão, valores mínimo e máximo, além da quantidade de valores positivos, negativos e iguais a zero. Essa tabela permite observar a transição entre fases com expansão relevante e fases em que a retração passa a predominar.

Arquivo de origem: [experimento_01_caracterizacao/resultados/estatisticas_por_idade.csv](#)

idade_label	registros	media	mediana	desvio_padrao	minimo	maximo	positivos	negativos	zeros
12 h	207	0.097	0	1.704	-10	20	2	1	204
1 dia	207	11.594	20	68.563	-130	410	118	78	11
3 dias	207	19.855	50	119.763	-250	700	125	82	0
7 dias	207	15.749	70	177.267	-450	910	124	83	0
14 dias	207	-105.749	-80	155.78	-560	720	25	178	4
28 dias	206	-224.223	-220	148.643	-870	430	7	199	0
56 dias	206	-358.592	-350	145.376	-1000	210	5	201	0

Tabela 2 — Contagem dos sinais por idade

A Tabela 2 organiza os dados por classe de sinal: estabilidade, expansão e retração. Ela é importante porque evidencia que as idades iniciais apresentam comportamento misto, enquanto idades mais avançadas concentram maior quantidade de valores negativos.

Arquivo de origem: [experimento_01_caracterizacao/resultados/contagem_sinais_por_idade.csv](#)

idade_label	estabilidade	expansao	retracao
12 h	204	2	1
1 dia	11	118	78
3 dias	0	125	82
7 dias	0	124	83
14 dias	4	25	178
28 dias	0	7	199
56 dias	0	5	201

Figura 1 — Média da variação dimensional por idade

A Figura 1 apresenta a média da variação dimensional em ordem temporal. O gráfico permite visualizar a evolução média do fenômeno ao longo do tempo, evitando interpretação apenas pontual aos 28 dias.





Figura 2 — Distribuição da variação dimensional por idade

A Figura 2 apresenta a dispersão da variação dimensional por idade. O boxplot permite identificar amplitude, assimetria e presença de valores extremos em cada etapa temporal.



6. Interpretação dos resultados

Os resultados confirmam que a resposta experimental varia ao longo do tempo e que o sinal é parte relevante da interpretação física. O experimento mostra que a expansão, a retração e a estabilidade dimensional coexistem na base, especialmente nas idades iniciais.

7. Conclusão do experimento

O Experimento 1 justifica a escolha de `epsilon_t` como variável de resposta longitudinal com sinal. A partir dele, a sequência experimental passa a tratar a predição como um problema de regressão temporal da variação dimensional, e não como predição isolada da magnitude absoluta da retração.

Discussão teórica e justificativa metodológica

A primeira decisão do experimento foi tratar a resposta como **variação dimensional com sinal**, e não apenas como retração. Essa escolha encontra respaldo no próprio comportamento físico descrito nos estudos sobre retração, aditivos expansivos e fibras. Khajehdehi et al. (2018) analisam combinações de cura interna, materiais cimentícios suplementares e aditivos expansivos, mostrando que a resposta dimensional do concreto pode envolver mecanismos de redução de retração e efeitos expansivos. Statkauskas et al. (2022) também abordam aditivos redutores de retração e combinações com fibras, associando a deformação dimensional a respostas de composição e idade. Assim, preservar valores positivos, negativos e nulos mantém no banco de dados a distinção entre expansão, retração e estabilidade.

A segunda decisão foi iniciar a sequência por uma etapa descritiva. Essa opção é coerente com Taffese et al. (2025), que discutem limitações recorrentes em bases de dados de durabilidade do concreto, incluindo disponibilidade, heterogeneidade e necessidade de compreensão prévia do domínio. Antes do treinamento de modelos, a caracterização por idade permite verificar distribuição, dispersão e predominância dos sinais físicos. Folorunsho et al. (2024) também reforçam a relevância das primeiras idades no controle de fissuras por retração plástica, o que sustenta a leitura temporal das medições.

A análise por idade permite observar a transição entre expansão inicial, estabilidade e retração progressiva. Essa leitura aproxima o experimento da proposta, pois o sistema preditivo não se limita a estimar um valor final; ele representa a evolução longitudinal da deformação dimensional.

Experimento 2 — Construção da base longitudinal

Síntese teórico-metodológica

O segundo experimento transformou a planilha original, organizada com uma coluna por idade, em uma base longitudinal. Cada linha passou a representar uma combinação entre amostra e idade, tendo `epsilon_t` como variável de resposta. Essa estrutura permite modelar a evolução da deformação ao longo do tempo, em vez de predizer apenas uma idade isolada.

Essa decisão dialoga com estudos de machine learning aplicados à deformação dimensional de materiais cimentícios. Hilloulin e Umunnakwe (2024), Hilloulin e Tran (2023), Ocak et al. (2024) e Qureshi et al. (2022) analisam respostas associadas à retração e à evolução temporal de materiais cimentícios a partir de variáveis de composição e condições experimentais. A inclusão explícita da idade como atributo explicativo permite ao modelo reconhecer padrões temporais da variação dimensional.

A criação de `amostra_id` teve papel metodológico relevante. Diferentes idades de uma mesma amostra não constituem observações independentes. Kaufman et al. (2012) discutem vazamento de informação em mineração de dados, especialmente quando a estrutura dos dados permite que informação relacionada ao alvo apareça indevidamente no treinamento. A identificação por amostra permite aplicar validação agrupada nos experimentos seguintes.

Desenvolvimento detalhado do experimento

1. Caracterização e finalidade

Este experimento transforma a base original em uma estrutura longitudinal. A finalidade é reorganizar as medições de variação dimensional de diferentes idades em uma única variável de resposta, denominada `epsilon_t`, acompanhada de uma variável temporal explícita.

A estrutura longitudinal é necessária porque o objetivo do sistema preditivo é estimar a **variação dimensional ao longo do tempo**, e não apenas um ponto específico da curva.

2. Variável de resposta

A variável de saída passa a ser:

```
epsilon_t = variação dimensional na idade t, em µm/m
```

As idades foram representadas por três atributos:

- `idade_label`: rótulo textual da idade;
- `idade_dias`: idade em dias;
- `idade_horas`: idade em horas.

amostra_id	wb	cement_consumption	water_consumption	dry_d1	fibra_metalica	macrofibra_pp	microfibra_pp	cement_consumption
39	0.51	380	193.8	0	0	0	0.6	CPV ARI RS
143	0.55	336	184.8	15	0	0	0.6	CP II 40
38	0.55	335	184.25	12.5	0	5.5	0.6	CP II 40
144	0.49	380	186.2	0	0	5.5	0.6	CPV ARI RS
145	0.528	360	190.08	15	0	0	0.6	CP II 32 R
37	0.55	340	187	0	0	0	0.6	CP II 40
146	0.55	336	184.8	0	0	5.5	0	CP II 40
142	0.52	356	185.12	0	0	0	0.6	CP II 40
42	0.55	327	179.85	0	25	0	0.6	CP II 40
136	0.53	340	180.2	0	0	5.5	0.6	CP II 40

amostra_id	wb	cement_consumption	water_consumption	dry_d1	fibra_metallica	macrofibra_pp	microfibra_pp	cementos
43	0.51	380	193.8	12.5	0	6	0.6	CP II RS
126	0.62	311	192.82	0	25	0	0	CP II 40
48	0.55	336	184.8	0	25	0	0.6	CP V ARI
127	0.51	380	193.8	12.5	0	0	0.6	CP V ARI RS
128	0.54	344	185.76	0	0	2.236	0	CP II 40
47	0.55	336	184.8	10	25	4	0.6	CP II 40
129	0.54	341	184.14	15	25	0	0.6	CP II 40
106	0.6	339	203.4	0	25	0	0.6	CP II 40
59	0.547	320	175.04	0	0	0	0.6	CP II 40
168	0.53	360	190.8	0	0	0	0	CP V ARI

amostra_id	wb	cement_consumption	water_consumption	dry_d1	fibra_metalica	macrofibra_pp	microfibra_pp	cement_consumption
22	0.55	360	198	0	0	5	0	CPI 40
107	0.62	325	201.5	8	0	0	0.3	CPV ARI
58	0.49	380	186.2	10	0	0	0.6	CPV ARI
167	0.55	336	184.8	15	0	5.5	0.6	CPI 40
108	0.52	356	185.12	15	0	0	0.6	CPI 40
27	0.52	327	170.04	10	0	0	0	CPI 40
38	0.55	335	184.25	12.5	0	5.5	0.6	CPI 40

Observação: o CSV completo correspondente permanece disponível na pasta de resultados do experimento.

5. Arquivo complementar

Além do CSV, foi gerado o arquivo `base_longitudinal.xlsx`, que contém a mesma base em formato de planilha. Também foi gerado `resumo_base_longitudinal.txt`, com o resumo textual da transformação.

6. Interpretação dos resultados

A transformação aumenta o número de registros analíticos, pois cada amostra passa a aparecer em múltiplas linhas, uma para cada idade. Isso permite que o modelo aprenda a relação entre composição, condição experimental e tempo.

O uso de `amostra_id` é metodologicamente importante: nas validações posteriores, as diferentes idades de uma mesma amostra devem permanecer no mesmo grupo, reduzindo o risco de vazamento de dados entre treino e teste.

7. Conclusão do experimento

O Experimento 2 constrói a base efetiva para a modelagem longitudinal. A partir desta etapa, todos os modelos passam a prever `epsilon_t`, preservando o sinal da variação dimensional.

Discussão teórica e justificativa metodológica

A transformação da base original para o formato longitudinal foi adotada porque a variação dimensional é um fenômeno dependente do tempo. Os trabalhos de Hilloulin e Umnakwe (2024), Hilloulin e Tran (2023), Ocak et al. (2024) e Qureshi et al. (2022) tratam a retração como resposta associada à composição do material, às condições de cura e à idade ou duração de exposição. Portanto, representar cada idade como uma observação associada a `epsilon_t` permite que o modelo aprenda a evolução temporal da resposta, em vez de restringir a análise a uma idade única.

A variável `idade_dias` foi mantida como atributo explicativo para que o modelo capture a trajetória da deformação. A criação de `amostra_id` também tem função metodológica relevante: diferentes idades de um mesmo traço não são observações independentes. Kaufman et al. (2012) discutem o risco de vazamento de informação quando atributos ou registros relacionados ao alvo aparecem indevidamente no treinamento. Nesse contexto, o identificador de amostra oferece a base para validações agrupadas nos experimentos seguintes.

A criação da classe de sinal — retração, expansão ou estabilidade — não substitui a regressão de `epsilon_t`. Ela funciona como camada interpretativa complementar. Essa decisão preserva a resposta contínua em $\mu\text{m/m}$ e, ao mesmo tempo, permite avaliar se o modelo conserva o sentido físico da deformação.

Experimento 3 — Baseline com Ridge Regression

Síntese teórico-metodológica

O terceiro experimento estabeleceu um modelo de referência com Ridge Regression. O objetivo foi obter um ponto inicial de comparação com um modelo linear regularizado e relativamente interpretável. A escolha do baseline permitiu avaliar quanto da variação dimensional longitudinal poderia ser explicada por relações lineares entre dosagem, idade, materiais e variáveis categóricas.

A existência de um baseline é coerente com a literatura de avaliação de modelos. Kohavi (1995) e Arlot e Celisse (2010) tratam a validação cruzada como estratégia de estimativa de desempenho e seleção de modelos. A validação por grupo foi mantida para evitar que idades do mesmo traço aparecessem simultaneamente em treino e teste, considerando a discussão de Kaufman et al. (2012) sobre vazamento de dados.

As métricas MAE, RMSE, R^2 e acurácia do sinal foram avaliadas em conjunto. Willmott e Matsuura (2005) discutem o MAE como medida direta do erro médio, enquanto Chai e Draxler (2014) defendem a permanência do RMSE quando se busca evidenciar erros maiores. A acurácia do sinal acrescenta uma leitura física, ao verificar se o modelo acerta retração, expansão ou estabilidade.

Desenvolvimento detalhado do experimento

1. Caracterização e finalidade

Este experimento estabelece um modelo de referência para a predição longitudinal da variação dimensional. A finalidade é obter um desempenho inicial com um algoritmo linear regularizado e interpretável, usando `Ridge Regression`.

O modelo baseline serve como parâmetro mínimo de comparação para os experimentos seguintes. Modelos mais complexos só são metodologicamente justificáveis se melhorarem o erro, a explicação da variância ou a acurácia do sinal em relação a esse ponto de partida.

2. Variáveis utilizadas

A variável de resposta é `epsilon_t`. As variáveis de entrada incluem dosagem, materiais, cura, local de ensaio, estado, região e idade.

O experimento utiliza validação por grupo com `amostra_id`, evitando que idades da mesma amostra sejam simultaneamente usadas em treino e teste.

3. Procedimento executado

Foi construído um pipeline com pré-processamento para variáveis numéricas e categóricas, seguido de Ridge Regression. O modelo foi avaliado por validação cruzada agrupada, gerando métricas globais, predições fora da amostra, resíduos e gráfico real versus previsto.

Tabela 4 — Métricas do modelo baseline Ridge

A Tabela 4 apresenta as métricas globais do modelo baseline: MAE, RMSE, R^2 e acurácia do sinal. O MAE indica o erro médio em $\mu\text{m/m}$; o RMSE penaliza erros maiores; o R^2 indica a proporção de variabilidade explicada; e a acurácia do sinal verifica se o modelo acerta expansão, retração ou estabilidade.

Arquivo de origem: `experimento_03_baseline_ridge/resultados/metricas_baseline_ridge.csv`

MAE	RMSE	R2	acuracia_sinal
63.161	96.159	0.74	0.794

Tabela 5 — Predições do modelo baseline

A Tabela 5 contém as predições fora da amostra para cada registro longitudinal. Ela apresenta valor real, valor previsto, resíduo, erro absoluto e classificação do sinal real e previsto. Essa tabela permite investigar casos em que o modelo acerta a tendência geral, mas erra a magnitude, e casos em que erra o próprio sentido físico da deformação.

Arquivo de origem: [experimento_03_baseline_ridge/resultados/predicoes_baseline_ridge.csv](#)

A tabela completa possui **1447 registros** e **9 colunas**. Para manter a leitura viável, apresenta-se abaixo uma visualização parcial, mantendo o arquivo CSV completo na pasta de resultados.


amostra_id	idade_label	idade_dias	epsilon_t	epsilon_previsto	residuo	erro_absoluto	sinal_real	sinal_previsto
0	12 h	0.5	0	32.305	-32.305	32.305	estabilidade	expansao
138	12 h	0.5	0	-88.521	88.521	88.521	estabilidade	retracao
41	12 h	0.5	0	38.203	-38.203	38.203	estabilidade	expansao
139	12 h	0.5	0	88.916	-88.916	88.916	estabilidade	expansao
140	12 h	0.5	0	-91.485	91.485	91.485	estabilidade	retracao
40	12 h	0.5	0	88.916	-88.916	88.916	estabilidade	expansao
141	12 h	0.5	0	70.388	-70.388	70.388	estabilidade	expansao
137	12 h	0.5	0	28.276	-28.276	28.276	estabilidade	expansao
39	12 h	0.5	0	-129.466	129.466	129.466	estabilidade	retracao
143	12 h	0.5	0	43.646	-43.646	43.646	estabilidade	expansao
38	12 h	0.5	0	66.696	-66.696	66.696	estabilidade	expansao
144	12 h	0.5	0	-103.843	103.843	103.843	estabilidade	retracao
145	12 h	0.5	0	106.164	-106.164	106.164	estabilidade	expansao
37	12 h	0.5	0	-74.512	74.512	74.512	estabilidade	retracao
146	12 h	0.5	0	-60.599	60.599	60.599	estabilidade	retracao
142	12 h	0.5	0	-108.743	108.743	108.743	estabilidade	retracao
42	12 h	0.5	0	-77.575	77.575	77.575	estabilidade	retracao
136	12 h	0.5	0	-110.012	110.012	110.012	estabilidade	retracao
43	12 h	0.5	0	48.468	-48.468	48.468	estabilidade	expansao
126	12 h	0.5	0	-53.399	53.399	53.399	estabilidade	retracao
48	12 h	0.5	0	-79.949	79.949	79.949	estabilidade	retracao
127	12 h	0.5	0	18.381	-18.381	18.381	estabilidade	expansao
128	12 h	0.5	0	-108.644	108.644	108.644	estabilidade	retracao
47	12 h	0.5	0	60.28	-60.28	60.28	estabilidade	expansao
129	12 h	0.5	0	129.691	-129.691	129.691	estabilidade	expansao
106	56 dias	56	-430	-398.106	-31.894	31.894	retracao	retracao
59	56 dias	56	-460	-434.547	-25.453	25.453	retracao	retracao
168	56 dias	56	-390	-451.99	61.99	61.99	retracao	retracao
22	56 dias	56	-590	-444.076	-145.924	145.924	retracao	retracao

amostra_id	idade_label	idade_dias	epsilon_t	epsilon_previsto	residuo	erro_absoluto	sinal_real	sinal_previsto
107	56 dias	56	-360	-341.469	-18.531	18.531	retracao	retracao
58	56 dias	56	-320	-373.751	53.751	53.751	retracao	retracao
167	56 dias	56	-260	-261.005	1.005	1.005	retracao	retracao
108	56 dias	56	-290	-248.764	-41.236	41.236	retracao	retracao
27	56 dias	56	-350	-281.263	-68.737	68.737	retracao	retracao
38	56 dias	56	-350	-288.252	-61.748	61.748	retracao	retracao

Observação: o CSV completo correspondente permanece disponível na pasta de resultados do experimento.

Figura 3 — Real versus previsto no baseline Ridge

A Figura 1 compara valores reais e previstos. Quanto mais próximos os pontos estiverem da linha de identidade, melhor a predição. A dispersão em torno da linha mostra o erro do baseline.



6. Interpretação dos resultados

O baseline fornece uma referência interpretável para a sequência. Como modelo linear, ele tende a capturar tendências gerais, mas pode ter limitação diante de relações não lineares entre idade, aditivo, fibras, cura e composição.

7. Conclusão do experimento

O Experimento 3 estabelece a referência inicial da modelagem. Os experimentos posteriores devem demonstrar se modelos não lineares e estratégias de seleção ou ajuste fino aumentam a capacidade preditiva para `epsilon_t`.

Discussão teórica e justificativa metodológica

O uso de um modelo baseline interpretável foi adotado para estabelecer uma referência inicial de desempenho. A literatura de validação e seleção de modelos, especialmente Kohavi (1995) e Arlot e Celisse (2010), sustenta a comparação entre alternativas preditivas a partir de estimativas obtidas por validação cruzada. Nesse experimento, a Ridge Regression cumpre a função de referência linear regularizada: ela permite avaliar quanto da variação dimensional longitudinal pode ser explicada por uma combinação linear das variáveis de dosagem, idade e categorias experimentais.

A validação agrupada por `amostra_id` foi mantida para reduzir a possibilidade de vazamento entre idades do mesmo traço. Essa escolha dialoga diretamente com Kaufman et al. (2012), uma vez que registros temporalmente relacionados podem produzir desempenho artificialmente elevado quando são separados de forma aleatória entre treino e teste.

As métricas MAE, RMSE, R^2 e acurácia do sinal foram usadas de forma complementar. Willmott e Matsuura (2005) discutem o MAE como medida direta do erro médio, enquanto Chai e Draxler (2014) defendem que MAE e RMSE podem ser analisados conjuntamente, pois expressam aspectos diferentes do erro. A acurácia do sinal aproxima a avaliação estatística da leitura física do fenômeno, verificando se a previsão preserva retração, expansão ou estabilidade.

Experimento 4 — Comparação de modelos preditivos

Síntese teórico-metodológica

O quarto experimento comparou modelos lineares e não lineares, incluindo Random Forest, Extra Trees e Gradient Boosting. A decisão foi motivada pela natureza multivariável e potencialmente não linear da variação dimensional do concreto. A literatura aplicada mostra que modelos de machine learning têm sido utilizados para prever respostas dimensionais associadas à retração em materiais cimentícios, considerando proporções de mistura, SCMs, polímeros, resíduos e variáveis ambientais (Hilloulin e Umnakwe, 2024; Hilloulin e Tran, 2023; Ocak et al., 2024; Qureshi et al., 2022).

Breiman (2001) fundamenta Random Forest como ensemble de árvores aplicável à regressão. Geurts et al. (2006) fundamentam Extra Trees, cuja randomização de atributos e pontos de corte permite lidar com relações complexas. Friedman (2001) fundamenta Gradient Boosting como aproximação funcional aditiva otimizada por gradiente.

A comparação foi conduzida com a mesma base, a mesma variável `epsilon_t` e o mesmo esquema de validação agrupada. Essa padronização fortalece a leitura comparativa, pois reduz interferências do protocolo de validação.

Desenvolvimento detalhado do experimento

1. Caracterização e finalidade

Este experimento compara diferentes algoritmos de regressão para prever a variação dimensional longitudinal com sinal. A finalidade é verificar se modelos não lineares superam o baseline linear do Experimento 3.

2. Modelos avaliados

Foram comparados modelos lineares e baseados em árvores. Todos utilizaram a mesma base longitudinal, a mesma variável de resposta `epsilon_t` e validação por grupo baseada em `amostra_id`.

3. Procedimento executado

Cada modelo foi inserido em um pipeline com pré-processamento de variáveis numéricas e categóricas. As métricas foram calculadas por validação cruzada agrupada, e as predições de cada modelo foram exportadas para análise comparativa.

Tabela 5 — Comparação global dos modelos

A Tabela 5 apresenta a comparação entre os modelos. O ranqueamento principal deve considerar o RMSE, pois ele penaliza erros maiores. Também devem ser observados MAE, R^2 e acurácia do sinal para avaliar simultaneamente magnitude e sentido físico da predição.

Arquivo de origem: `experimento_04_comparacao_modelos/resultados/comparacao_modelos.csv`

MAE	RMSE	R2	acuracia_sinal	modelo	MAE_cv_medio	MAE_cv_desvio	RMSE_cv_medio	RMSE_cv_desvio	R
48.323	86.096	0.792	0.803	Gradient Boosting	48.328	5.813	84.061	18.697	
48.44	86.232	0.791	0.884	Extra Trees	48.446	5.329	85.136	13.82	
48.468	88.208	0.781	0.857	Random Forest	48.473	4.317	87.467	11.511	
63.161	96.159	0.74	0.794	Ridge	63.167	5.998	95.09	14.454	

Tabela 6 — Predições por modelo

A Tabela 6 reúne as predições dos modelos comparados para cada registro longitudinal. Ela permite comparar, caso a caso, o erro produzido por cada algoritmo e identificar padrões em que determinado modelo se comporta melhor ou pior.

Arquivo de origem: [experimento_04_comparacao_modelos/resultados/predicoes_por_modelo.csv](#)

A tabela completa possui **1447 registros** e **11 colunas**. Para manter a leitura viável, apresenta-se abaixo uma visualização parcial, mantendo o arquivo CSV completo na pasta de resultados.


amostra_id	idade_label	epsilon_t	pred_Ridge	erro_Ridge	pred_Random Forest	erro_Random Forest	pred_Gradient Boosting	erro_Gradient Boosting
0	12 h	0	32.305	32.305	0.211	0.211	17.273	17.273
138	12 h	0	-88.521	88.521	0	0	-16.132	16.132
41	12 h	0	38.203	38.203	-0.66	0.66	14.344	14.344
139	12 h	0	88.916	88.916	-0.067	0.067	29.159	29.159
140	12 h	0	-91.485	91.485	0	0	-22.674	22.674
40	12 h	0	88.916	88.916	-0.067	0.067	29.159	29.159
141	12 h	0	70.388	70.388	0.15	0.15	15.789	15.789
137	12 h	0	28.276	28.276	1.375	1.375	5.364	5.364
39	12 h	0	-129.466	129.466	0	0	-25.901	25.901
143	12 h	0	43.646	43.646	0	0	8.693	8.693
38	12 h	0	66.696	66.696	0.577	0.577	12.964	12.964
144	12 h	0	-103.843	103.843	0	0	-19.851	19.851
145	12 h	0	106.164	106.164	0.283	0.283	29.159	29.159
37	12 h	0	-74.512	74.512	0	0	-22.403	22.403
146	12 h	0	-60.599	60.599	14.727	14.727	-1.849	1.849
142	12 h	0	-108.743	108.743	0	0	-32.801	32.801
42	12 h	0	-77.575	77.575	0	0	-16.132	16.132
136	12 h	0	-110.012	110.012	-3.506	3.506	-12.194	12.194
43	12 h	0	48.468	48.468	7.07	7.07	13.213	13.213
126	12 h	0	-53.399	53.399	0	0	-6.806	6.806
48	12 h	0	-79.949	79.949	0	0	-16.132	16.132
127	12 h	0	18.381	18.381	0.028	0.028	13.213	13.213
128	12 h	0	-108.644	108.644	0	0	-22.674	22.674
47	12 h	0	60.28	60.28	0	0	17.562	17.562

amostra_id	idade_label	epsilon_t	pred_Ridge	erro_Ridge	pred_Random Forest	erro_Random Forest	pred_Gradient Boosting	erro_Gradient Boosting
129	12 h	0	129.691	129.691	0.491	0.491	21.173	21.173
106	56 dias	-430	-398.106	31.894	-360.957	69.043	-366.304	63.696
59	56 dias	-460	-434.547	25.453	-452.914	7.086	-418.917	41.083
168	56 dias	-390	-451.99	61.99	-429.327	39.327	-422.652	32.652
22	56 dias	-590	-444.076	145.924	-425.618	164.382	-421.521	168.479
107	56 dias	-360	-341.469	18.531	-415.523	55.523	-322.837	37.163
58	56 dias	-320	-373.751	53.751	-323.005	3.005	-296.194	23.806
167	56 dias	-260	-261.005	1.005	-277.72	17.72	-280.616	20.616
108	56 dias	-290	-248.764	41.236	-304.442	14.442	-277.605	12.395
27	56 dias	-350	-281.263	68.737	-350.765	0.765	-296.509	53.491
38	56 dias	-350	-288.252	61.748	-335.362	14.638	-296.377	53.623

Observação: o CSV completo correspondente permanece disponível na pasta de resultados do experimento.

Figura 4 — Comparação dos modelos por RMSE

A Figura 4 apresenta o RMSE de cada modelo. Como RMSE é uma métrica de erro, a menor barra indica o melhor desempenho global.



6. Interpretação dos resultados

O melhor modelo pelo critério de RMSE foi **Gradient Boosting**, com RMSE de 86.096 $\mu\text{m/m}$, MAE de 48.323 $\mu\text{m/m}$, R^2 de 0.792 e acurácia do sinal de 0.803. Esse resultado indica que a relação entre variáveis de entrada e variação dimensional tem componente não linear relevante.

7. Conclusão do experimento

O Experimento 4 identifica o desempenho relativo dos algoritmos e orienta a escolha dos modelos mais promissores para as etapas seguintes. A comparação sustenta a continuidade com modelos de maior capacidade preditiva, sem abandonar a análise de sinal.

Discussão teórica e justificativa metodológica

A comparação entre modelos lineares e modelos baseados em árvores foi adotada porque a variação dimensional do concreto envolve relações potencialmente não lineares entre idade, consumo de água, cimento, fibras, aditivos e condições de cura. Os estudos aplicados de Hilloulin e Umunnakwe (2024), Hilloulin e Tran (2023), Ocak et al. (2024) e Qureshi et al. (2022) demonstram a pertinência de técnicas de aprendizado de máquina para prever respostas dimensionais de materiais cimentícios a partir de variáveis de mistura e condições experimentais.

Random Forest, Extra Trees e Gradient Boosting foram incluídos por representarem famílias de modelos ensemble com capacidade de capturar interações e não linearidades. Breiman (2001) fundamenta o uso de florestas aleatórias em tarefas de classificação e regressão. Geurts et al. (2006) fundamentam o Extra Trees, modelo baseado em árvores extremamente randomizadas. Friedman (2001) fundamenta o Gradient Boosting como aproximação funcional aditiva otimizada por gradiente.

A manutenção da mesma base longitudinal e da mesma validação agrupada para todos os modelos reduz variações decorrentes do protocolo experimental. Desse modo, a comparação passa a refletir mais diretamente as diferenças entre algoritmos, e não diferenças de amostragem, pré-processamento ou particionamento.

Experimento 5 — Comparação das formulações da variável-alvo

Síntese teórico-metodológica

O quinto experimento comparou três leituras da resposta: variação dimensional com sinal, magnitude absoluta e classe dimensional. Essa etapa foi decisiva para mostrar que a modelagem da magnitude absoluta não é equivalente à modelagem da variação dimensional. Ao retirar o sinal, perde-se a distinção entre expansão e retração.

Khajehdehi et al. (2018), Statkauskas et al. (2022) e Folorunsho et al. (2024) sustentam a relevância física dessa distinção, pois aditivos, fibras e condições de cura podem atuar de forma diferente na expansão inicial, na redução da retração e no controle de fissuras. A variável `epsilon_t` preserva essa informação.

As métricas de classificação foram usadas como avaliação complementar do sinal físico. Powers (2011) discute precision, recall e F-measure, destacando suas limitações e vieses. Sokolova e Lapalme (2009) sistematizam métricas de classificação em cenários binários e multiclasse. Por isso, matriz de confusão, precision, recall e F1 foram usadas para interpretar a classe dimensional, enquanto MAE, RMSE e R² permaneceram associadas à regressão.

Desenvolvimento detalhado do experimento

1. Caracterização e finalidade

Este experimento avalia diferentes formas de representar a variável de resposta. A finalidade é verificar as consequências metodológicas de prever a variação dimensional com sinal, a magnitude absoluta da deformação e a classe dimensional.

A comparação é importante porque a variável com sinal preserva a distinção física entre retração e expansão, enquanto o módulo absoluto informa apenas a intensidade da deformação.

2. Formulações avaliadas

Foram consideradas três formulações:

- 1. `epsilon_t`: variação dimensional com sinal;
- 2. `abs(epsilon_t)`: magnitude absoluta da deformação;
- 3. classe dimensional: retração, expansão ou estabilidade.

3. Procedimento executado

Foram treinados modelos de regressão para as duas formulações numéricas e um modelo de classificação para a classe dimensional. As saídas foram comparadas por métricas adequadas a cada tipo de problema.

Tabela 6 — Métricas de regressão para as formulações numéricas

A Tabela 6 compara a predição da variação dimensional com sinal e da magnitude absoluta. A comparação ajuda a demonstrar que a formulação com sinal é conceitualmente mais adequada ao objetivo principal, enquanto a magnitude absoluta pode ser usada como análise complementar de intensidade.

Arquivo de origem: `experimento_05_formulacoes_alvo/resultados/metricas_regressao_formulacoes.csv`

MAE	RMSE	R2	acuracia_sinal	formulacao
63.161	96.159	0.74	0.794	variacao_com_sinal
59.9	95.398	0.585	0.839	magnitude_absoluta

Tabela 7 — Métricas da classificação dimensional

A Tabela 7 apresenta accuracy, precision macro, recall macro e F1 macro para a classificação entre retração, expansão e estabilidade. Essas métricas avaliam o desempenho na identificação do comportamento dimensional, e não na magnitude numérica da deformação.

Arquivo de origem: [experimento_05_formulacoes_alvo/resultados/metricas_classe_dimensional.csv](#)

formulacao	accuracy	precision_macro	recall_macro	f1_macro
classe_dimensional	0.924	0.929	0.921	0.925

Tabela 8 — Matriz de confusão da classe dimensional

A Tabela 8 mostra a matriz de confusão da classificação dimensional. As linhas correspondem às classes reais e as colunas às classes previstas. A diagonal principal representa acertos; valores fora da diagonal indicam confusões entre retração, expansão e estabilidade.

Arquivo de origem: [experimento_05_formulacoes_alvo/resultados/matriz_confusao_classe_dimensional.csv](#)

Unnamed: 0	estabilidade	expansao	retracao
estabilidade	207	7	5
expansao	3	356	47
retracao	1	47	774

Tabela 9 — Predições da variação com sinal

A Tabela 9 contém as predições da formulação principal, isto é, `epsilon_t` com sinal. Ela permite verificar se o modelo preserva o sentido físico da deformação.

Arquivo de origem: [experimento_05_formulacoes_alvo/resultados/predicoes_variacao_com_sinal.csv](#)

A tabela completa possui **1447 registros** e **4 colunas**. Para manter a leitura viável, apresenta-se abaixo uma visualização parcial, mantendo o arquivo CSV completo na pasta de resultados.

amostra_id	idade_label	real	previsto
0	12 h	0	32.305
138	12 h	0	-88.521
41	12 h	0	38.203
139	12 h	0	88.916
140	12 h	0	-91.485
40	12 h	0	88.916
141	12 h	0	70.388
137	12 h	0	28.276
39	12 h	0	-129.466
143	12 h	0	43.646
38	12 h	0	66.696
144	12 h	0	-103.843
145	12 h	0	106.164
37	12 h	0	-74.512
146	12 h	0	-60.599
142	12 h	0	-108.743
42	12 h	0	-77.575

amostra_id	idade_label	real	previsto
136	12 h	0	-110.012
43	12 h	0	48.468
126	12 h	0	-53.399
48	12 h	0	-79.949
127	12 h	0	18.381
128	12 h	0	-108.644
47	12 h	0	60.28
129	12 h	0	129.691
106	56 dias	-430	-398.106
59	56 dias	-460	-434.547
168	56 dias	-390	-451.99
22	56 dias	-590	-444.076
107	56 dias	-360	-341.469
58	56 dias	-320	-373.751
167	56 dias	-260	-261.005
108	56 dias	-290	-248.764
27	56 dias	-350	-281.263
38	56 dias	-350	-288.252

Observação: o CSV completo correspondente permanece disponível na pasta de resultados do experimento.

Tabela 10 — Predições da magnitude absoluta

A Tabela 10 contém as predições da magnitude absoluta. Essa formulação não distingue retração de expansão; por isso deve ser interpretada como medida complementar da intensidade da deformação.

Arquivo de origem: [experimento_05_formulacoes_alvo/resultados/predicoes_magnitude_absoluta.csv](#)

A tabela completa possui **1447 registros e 4 colunas**. Para manter a leitura do relatório viável, apresenta-se abaixo uma visualização parcial, mantendo o arquivo CSV completo na pasta de resultados.

amostra_id	idade_label	real	previsto
0	12 h	0	-21.704
138	12 h	0	10.128
41	12 h	0	-0.557
139	12 h	0	-34.798
140	12 h	0	25.598
40	12 h	0	-34.798
141	12 h	0	-51.576
137	12 h	0	-32.118
39	12 h	0	40.787
143	12 h	0	-34.287
38	12 h	0	-27.611
144	12 h	0	8.525

amostra_id	idade_label	real	previsto
145	12 h	0	-14.798
37	12 h	0	1.608
146	12 h	0	13.546
142	12 h	0	7.617
42	12 h	0	8.846
136	12 h	0	-13.76
43	12 h	0	58.221
126	12 h	0	-29.679
48	12 h	0	14.935
127	12 h	0	6.071
128	12 h	0	20.155
47	12 h	0	-24.802
129	12 h	0	-37.516
106	56 dias	430	343.772
59	56 dias	460	397.73
168	56 dias	390	379.694
22	56 dias	590	355.092
107	56 dias	360	369.28
58	56 dias	320	361.984
167	56 dias	260	328.044
108	56 dias	290	331.303
27	56 dias	350	376.269
38	56 dias	350	334.297

Observação: o CSV completo correspondente permanece disponível na pasta de resultados do experimento.

5. Interpretação dos resultados

A formulação com sinal é a mais adequada ao objetivo da dissertação, porque mantém a interpretação física. A formulação absoluta pode apresentar desempenho numérico competitivo, mas perde informação essencial. A classificação dimensional adiciona uma leitura categórica útil, mas não substitui a regressão de `epsilon_t`.

6. Conclusão do experimento

O Experimento 5 define que a variável principal dos experimentos deve permanecer `epsilon_t` com sinal. A magnitude absoluta e a classificação dimensional são úteis como análises complementares, mas não devem substituir a variável de resposta longitudinal.

Discussão teórica e justificativa metodológica

A comparação entre formulações da variável-alvo foi incluída para explicitar a diferença entre prever a **variação dimensional com sinal**, prever a **magnitude absoluta** e classificar o comportamento dimensional. Essa decisão é central para o escopo do trabalho e para a preservação do sentido físico da variável estudada. Khajehdehi et al. (2018), Statkauskas et al. (2022) e Folorunsho et al. (2024) indicam que as respostas dimensionais podem envolver efeitos de retração, expansão inicial, redução de fissuração e interação com fibras/aditivos. Nesse cenário, retirar o sinal da resposta elimina parte da informação física do fenômeno.

A formulação com `epsilon_t` preserva a direção da deformação. A formulação absoluta, por outro lado, informa apenas a intensidade da deformação, sem diferenciar expansão de retração. Essa distinção justifica a presença do experimento: ele mostra que uma boa predição da magnitude não equivale necessariamente a uma boa predição do comportamento dimensional.

As métricas de classificação foram usadas para avaliar a classe física do sinal. Powers (2011) discute precisão, revocação e F-measure, destacando que essas métricas precisam ser interpretadas considerando seus vieses. Sokolova e Lapalme (2009) sistematizam medidas de desempenho para classificação, incluindo problemas multiclasse. Por isso, matriz de confusão, precision, recall e F1 entram como avaliação complementar, e não como substituição das métricas de regressão.

Experimento 6 — Análise dos erros

Síntese teórico-metodológica

O sexto experimento investigou os resíduos por idade, cimento, cura, local, estado, região e faixas de variáveis quantitativas. Essa análise deslocou a avaliação do desempenho global para uma leitura diagnóstica. Em vez de considerar apenas o erro médio, o experimento analisou em quais regiões da base o modelo apresentou maior dificuldade.

Taffese et al. (2025) discutem que aplicações de machine learning em durabilidade do concreto enfrentam limitações relacionadas à heterogeneidade e à disponibilidade de dados. Essa discussão justifica a análise de domínio de validade. Ocak et al. (2024) e Folorunsho et al. (2024) também reforçam a importância da leitura temporal das deformações dimensionais e da fissuração, o que torna pertinente a análise dos erros por idade.

A exportação dos maiores erros e dos erros por grupo aumenta a rastreabilidade do modelo. Essa rastreabilidade é compatível com a preocupação de Kaufinan et al. (2012) sobre a separação entre aprendizagem e predição, além de favorecer a identificação de comportamentos fora do padrão.

Desenvolvimento detalhado do experimento

1. Caracterização e finalidade

Este experimento analisa os erros do modelo longitudinal. A finalidade é identificar onde o modelo apresenta maior dificuldade: por idade, tipo de cimento, cura, local, estado, região e faixas de variáveis quantitativas.

A análise de erro é essencial porque uma métrica global pode ocultar fragilidades localizadas. Um modelo pode ter bom RMSE médio, mas errar mais em uma idade específica ou em determinado grupo experimental.

2. Procedimento executado

O modelo foi aplicado à base longitudinal e os resíduos foram calculados para cada registro. Em seguida, os erros absolutos foram agrupados por variáveis categóricas e por faixas de variáveis numéricas. Também foram identificados os maiores erros individuais.

Tabela 11 — Base completa com erros

A Tabela 11 reúne a base longitudinal com as predições, resíduos e erros absolutos. Ela é a tabela central para auditoria do desempenho do modelo em nível de registro.

Arquivo de origem: [experimento_06_analise_erros/resultados/base_com_erros.csv](#)

A tabela completa possui **1447 registros** e **21 colunas**. Para manter a leitura viável, apresenta-se abaixo uma visualização parcial, mantendo o arquivo CSV completo na pasta de resultados.

wb	cement_consumption	water_consumption	dry_d1	fibra_metalina	macrofibra_pp	microfibra_pp	idade_dias	idade_meses
0.61	330	201.3	10	0	0	0.3	0.5	
0.55	336	184.8	0	0	5.5	0.6	0.5	
0.62	325	201.5	10	0	0	0.3	0.5	

wb	cement_consumption	water_consumption	dry_d1	fibra_metalica	macrofibra_pp	microfibra_pp	idade_dias	idade
0.55	336	184.8	15	0	0	0.6	0.5	
0.55	336	184.8	0	0	5.5	0.6	0.5	
0.55	336	184.8	15	0	0	0.6	0.5	
0.5	380	190	12	0	5	0.6	0.5	
0.51	373	190.23	10	0	0	0	0.5	
0.51	380	193.8	0	0	0	0.6	0.5	
0.55	336	184.8	15	0	0	0.6	0.5	
0.55	335	184.25	12.5	0	5.5	0.6	0.5	
0.49	380	186.2	0	0	5.5	0.6	0.5	
0.528	360	190.08	15	0	0	0.6	0.5	
0.55	340	187	0	0	0	0.6	0.5	

wb	cement_consumption	water_consumption	dry_d1	fibra_metalica	macrofibra_pp	microfibra_pp	idade_dias	idade
0.55	336	184.8	0	0	5.5	0	0.5	
0.52	356	185.12	0	0	0	0.6	0.5	
0.55	327	179.85	0	25	0	0.6	0.5	
0.53	340	180.2	0	0	5.5	0.6	0.5	
0.51	380	193.8	12.5	0	6	0.6	0.5	
0.62	311	192.82	0	25	0	0	0.5	
0.55	336	184.8	0	25	0	0.6	0.5	
0.51	380	193.8	12.5	0	0	0.6	0.5	
0.54	344	185.76	0	0	2.236	0	0.5	
0.55	336	184.8	10	25	4	0.6	0.5	

wb	cement_consumption	water_consumption	dry_d1	fibra_metalica	macrofibra_pp	microfibra_pp	idade_dias	idade
0.54	341	184.14	15	25	0	0.6	0.5	
0.6	339	203.4	0	25	0	0.6	56	
0.547	320	175.04	0	0	0	0.6	56	
0.53	360	190.8	0	0	0	0	56	
0.55	360	198	0	0	5	0	56	
0.62	325	201.5	8	0	0	0.3	56	
0.49	380	186.2	10	0	0	0.6	56	
0.55	336	184.8	15	0	5.5	0.6	56	
0.52	356	185.12	15	0	0	0.6	56	
0.52	327	170.04	10	0	0	0	56	

wb	cement_consumption	water_consumption	dry_d1	fibra_metalica	macrofibra_pp	microfibra_pp	idade_dias	idade
0.55	335	184.25	12.5	0	5.5	0.6	56	

Observação: o CSV completo correspondente permanece disponível na pasta de resultados do experimento.

Tabela 12 — Erro por idade

A Tabela 12 apresenta o erro médio, mediano e máximo por idade. Ela permite avaliar se o modelo tem maior dificuldade nas idades iniciais, intermediárias ou finais.

Arquivo de origem: [experimento_06_analise_erros/resultados/erro_por_idade.csv](#)

idade_label	quantidade	erro_medio	erro_mediano	erro_maximo	variacao_media
12 h	207	2.843	0	164.805	0.097
1 dia	207	28.072	16.282	245.5	11.594
3 dias	207	44.412	26.503	350.542	19.855
7 dias	207	61.318	30.123	480.742	15.749
14 dias	207	66.736	39.482	400.697	-105.749
28 dias	206	68.87	45.776	556.752	-224.223
56 dias	206	67.018	40.971	525.64	-358.592

Tabela 13 — Erro por tipo de cimento

A Tabela 13 mostra a distribuição dos erros por tipo de cimento. Ela ajuda a identificar se determinados cimentos estão associados a maior incerteza preditiva.

Arquivo de origem: [experimento_06_analise_erros/resultados/erro_por_cimento.csv](#)

cement	quantidade	erro_medio	erro_mediano	erro_maximo	variacao_media
CP II F 32	21	144.389	157.758	396.637	158.571
CP III RS	98	95.898	47.564	457.045	-31.224
CP II Z 32	35	66.829	51.392	207.08	25.429
CP V ARI	329	64.079	28.467	556.752	-124.316
CP V ARI RS	208	40.589	27.329	375.868	-113.029
CP II F 40	154	37.49	23.521	199.225	-90.974
CP II	14	35.883	29.763	99.352	-115
CP II E 40	476	35.837	17.265	359.328	-88.992
CP III	7	30.703	25.682	62.425	-91.429
CP II E 40 RS	14	24.762	15.104	78.173	-90.714
CP II F 32 RS	35	23.378	19.645	69.673	-88.286
Não informado	28	21.443	19.945	69.563	-110.357
CP II E	14	18.805	8.795	88.403	-95
CP II Z 40	14	15.798	14.131	43.635	-107.857

Tabela 14 — Erro por condição de cura

A Tabela 14 apresenta os erros por condição de cura. Essa análise é relevante porque a cura afeta diretamente a evolução da variação dimensional.

Arquivo de origem: [experimento_06_analise_erros/resultados/erro_por_cura.csv](#)

curing	quantidade	erro_medio	erro_mediano	erro_maximo	variacao_media
56 dias ar 50% umidade	7	226.577	269.341	442.057	-272.857
7 dias úmida / 56 dias ar 50% umidade	1370	48.254	25.077	556.752	-91.372
Não informado	70	34.264	14.361	284.975	-72.429

Tabela 15 — Erro por local de ensaio

A Tabela 15 compara os erros por local de ensaio. Diferenças entre laboratório, campo e registros não informados podem indicar efeito contextual ou heterogeneidade da base.

Arquivo de origem: [experimento_06_analise_erros/resultados/erro_por_local.csv](#)

local_ensaio	quantidade	erro_medio	erro_mediano	erro_maximo	variacao_media
Campo	28	251.571	266.196	556.752	-326.071
Laboratório	432	51.993	27.986	442.057	-72.894
Não informado	980	41.218	21.503	457.045	-92.745
Obra	7	27.663	28.208	48.769	-92.857

Tabela 16 — Erro por estado

A Tabela 16 apresenta o erro por estado. A leitura deve ser cuidadosa, pois estados com poucos registros podem produzir médias instáveis.

Arquivo de origem: [experimento_06_analise_erros/resultados/erro_por_estado.csv](#)

estado	quantidade	erro_medio	erro_mediano	erro_maximo	variacao_media
SC	42	121.182	108.76	396.637	28.81
RN	14	102.143	100.351	264.24	-186.429
ES	14	84.678	28.642	284.975	-200
RJ	182	80.783	45.664	457.045	-79.011
PR	28	74.824	74.482	167.292	-82.143
RS	35	66.829	51.392	207.08	25.429
PE	35	46.68	34.842	157.48	-102
MT	14	46.391	18.054	199.225	-110.714
SP	733	44.97	21.295	556.752	-99.973
MG	21	30.278	28.953	83.16	-76.667
BA	42	28.396	23.988	90.693	-90.476
PB	42	24.308	19.536	101.91	-106.19
PI	14	24.189	24.993	73.925	-127.857
AM	35	23.378	19.645	69.673	-88.286
AL	14	22.539	24.987	45.656	-107.857
CE	14	21.632	10.289	69.272	-105
DF	98	21.584	17.776	77.97	-95.408
SE	14	20.346	9.444	69.563	-112.857

estado	quantidade	erro_medio	erro_mediano	erro_maximo	variacao_media
TO	14	18.991	16.945	47.511	-92.143
PA	14	18.805	8.795	88.403	-95
SP	28	16.116	8.342	94.455	-88.929

Tabela 17 — Erro por região

A Tabela 17 agrupa os erros por região, permitindo verificar padrões espaciais mais agregados.

Arquivo de origem: [experimento_06_analise_erros/resultados/erro_por_regiao.csv](#)

regiao	quantidade	erro_medio	erro_mediano	erro_maximo	variacao_media
Sul	105	90.702	86.513	396.637	-1.905
Sudeste	978	51.061	24.133	556.752	-96.687
Nordeste	203	33.424	23.065	264.24	-108.768
Centro Oeste	112	24.684	17.94	199.225	-97.321
Norte	49	22.072	17.292	88.403	-90.204

Tabela 18 — Erro por faixa de relação a/c

A Tabela 18 organiza os erros por faixas da relação água/cimento. Essa variável é tecnicamente relevante para o comportamento dimensional.

Arquivo de origem: [experimento_06_analise_erros/resultados/erro_por_faixa_wb.csv](#)

faixa_wb	quantidade	erro_medio	erro_mediano	erro_maximo	variacao_media
(0.55, 0.63]	175	87.712	32.153	556.752	-138
(0.54, 0.55]	518	45.519	21.455	457.045	-72.876
(0.453, 0.51]	383	42.936	27.113	375.868	-107.285
(0.51, 0.54]	371	39.677	21.654	396.637	-78.625

Tabela 19 — Erro por faixa de consumo de cimento

A Tabela 19 avalia se o consumo de cimento está associado a faixas de maior erro preditivo.

Arquivo de origem: [experimento_06_analise_erros/resultados/erro_por_faixa_cement_consumption.csv](#)

faixa_cement_consumption	quantidade	erro_medio	erro_mediano	erro_maximo	variacao_media
(310.999, 336.0]	532	58.606	22.423	556.752	-83.139
(370.0, 424.0]	315	48.019	28.953	375.868	-109.016
(343.0, 370.0]	404	40.987	24.171	396.637	-87.45
(336.0, 343.0]	196	36.886	21.089	359.328	-93.163

Tabela 20 — Erro por faixa de consumo de água

A Tabela 20 avalia o erro por consumo de água. Essa leitura é importante porque a água participa diretamente das interações de dosagem e da evolução dimensional.

Arquivo de origem: [experimento_06_analise_erros/resultados/erro_por_faixa_water_consumption.csv](#)

faixa_water_consumption	quantidade	erro_medio	erro_mediano	erro_maximo	variacao_media
(192.0, 219.6]	350	69.444	32.634	556.752	-137.2

faixa_water_consumption	quantidade	erro_medio	erro_mediano	erro_maximo	variacao_media
(185.76, 192.0]	357	45.3	26.013	396.637	-81.176
(169.049, 184.8]	572	43.632	21.089	457.045	-68.724
(184.8, 185.76]	168	27.724	17.746	119.148	-94.345

Tabela 21 — Erro por faixa de DRY D1

A Tabela 21 avalia o erro por faixa de consumo de DRY D1, variável associada ao aditivo compensador de retração.

Arquivo de origem: [experimento_06_analise_erros/resultados/erro_por_faixa_dry_d1.csv](#)

faixa_dry_d1	quantidade	erro_medio	erro_mediano	erro_maximo	variacao_media
(12.5, 30.0]	280	54.188	19.319	457.045	11.714
(-0.001, 10.0]	887	50.224	25.95	556.752	-141.522
(10.0, 12.5]	280	37.041	22.674	247.138	-35.393

Tabela 22 — Maiores erros individuais

A Tabela 22 apresenta os maiores erros absolutos. Ela é útil para inspeção qualitativa dos casos mais difíceis e para identificar combinações de variáveis que o modelo ainda não representa adequadamente.

Arquivo de origem: [experimento_06_analise_erros/resultados/maiores_erros.csv](#)


wb	cement_consumption	water_consumption	dry_d1	fibra_metalica	macrofibra_pp	microfibra_pp	idade_dias	idade_
0.55	332	182.6	25		0	0.6	3	
0.61	330	201.3	0	0.000	0	0.3	7	
0.61	330	201.3	8	0.000	0	0.3	7	
0.55	332	182.6	25	0.000	0	0.6	7	
0.55	332	182.6	30	0.000	0	0.6	7	
0.6	339	203.4	0	25.000	0	0.6	7	

wb	cement_consumption	water_consumption	dry_d1	fibra_metalica	macrofibra_pp	microfibra_pp	idade_dias	idade_
0.61	330	201.3	0	0.000	0	0.3	7	
0.55	332	182.6	25		0	0.6	7	
0.55	332	182.6	30	0.000	0	0.6	14	
0.61	330	201.3	0	0.000	0	0.3	14	
0.55	332	182.6	25		0	0.6	14	
0.61	330	201.3	0	0.000	0	0.3	14	
0.51	380	193.8	10	25.000	5.625	0.6	14	
0.61	330	201.3	0	0.000	0	0.3	14	
0.61	330	201.3	8	0.000	0	0.3	14	
0.61	330	201.3	10	0.000	0	0.3	14	

wb	cement_consumption	water_consumption	dry_d1	fibra_metalica	macrofibra_pp	microfibra_pp	idade_dias	idade_
0.61	330	201.3	0	0.000	0	0.3	28	
0.61	330	201.3	10	0.000	0	0.3	28	
0.61	330	201.3	8	0.000	0	0.3	28	
0.61	330	201.3	0	0.000	0	0.3	28	
0.54	355	191.7	15	25.000	0	0.6	56	
0.61	330	201.3	0	0.000	0	0.3	56	
0.61	330	201.3	10	0.000	0	0.3	56	
0.61	330	201.3	8	0.000	0	0.3	56	
0.61	330	201.3	0	0.000	0	0.3	56	

Figura 4 — Erro médio por idade

A Figura 4 mostra o erro médio em ordem temporal. Ela ajuda a verificar em quais idades a predição é mais incerta.



5. Interpretação dos resultados

A análise por grupos torna a avaliação do modelo mais transparente. Em vez de depender apenas de métricas globais, o experimento mostra onde o sistema preditivo é mais robusto e onde requer cautela.

6. Conclusão do experimento

O Experimento 6 identifica os grupos e idades em que a predição é mais difícil. Essa informação orienta a interpretação do modelo final e evita uma defesa baseada apenas em métricas agregadas.

Discussão teórica e justificativa metodológica

A análise de erros por idade, materiais e grupos experimentais foi incluída para investigar onde o modelo apresenta maior ou menor aderência. Em bases de materiais cimentícios, Taffese et al. (2025) apontam a relevância de discutir domínio de validade, heterogeneidade e limitações dos dados. Assim, o erro médio global não esgota a avaliação; os resíduos por idade, cura, cimento, local e faixas de dosagem ajudam a identificar regiões em que a generalização é mais frágil.

A análise por idade se relaciona com os estudos de deformação dimensional e fissuração nas primeiras idades. Folorunsho et al. (2024) discutem o papel das fibras na retração plástica restringida, enquanto Ocak et al. (2024) usa aprendizado de máquina para estimar retração por secagem e largura de fissura ao longo do tempo. Essa literatura sustenta a leitura de que o erro pode variar conforme a idade, não apenas conforme o traço.

A decisão de exportar maiores erros, erros por grupos e base com resíduos aumenta a rastreabilidade do experimento. Essa rastreabilidade também se conecta à discussão de Kaufman et al. (2012), pois a auditoria de resíduos e agrupamentos contribui para identificar comportamentos artificiais, inconsistências ou domínios em que o modelo parece estar extrapolando.

Experimento 7 — Engenharia e seleção de atributos

Síntese teórico-metodológica

O sétimo experimento testou variáveis derivadas e métodos de seleção de atributos. A criação de interações entre idade, água, cimento, DRY D1 e fibras representou computacionalmente a hipótese de que os efeitos dos materiais não ocorrem de forma isolada. Khajehdehi et al. (2018) tratam de efeitos combinados entre cura interna, SCMs e aditivos expansivos. Hilloulin e Umunnakwe (2024) também enfatizam a relevância das proporções de mistura na predição de respostas dimensionais associadas à retração.

A seleção de atributos foi incorporada para avaliar se um subconjunto de variáveis poderia manter desempenho semelhante com menor complexidade. Essa decisão se aproxima da discussão de interpretabilidade de Lundberg e Lee (2017), segundo a qual a utilidade de um modelo não depende apenas da acurácia, mas também da possibilidade de compreender sua saída.

Os resultados indicaram que as variáveis derivadas não melhoraram de forma expressiva o desempenho global em relação ao uso das variáveis básicas com modelos baseados em árvores. Essa evidência sugere que, nesta base específica, parte das interações já foi capturada pelo próprio modelo, especialmente no caso do Extra Trees.

Desenvolvimento detalhado do experimento

1. Caracterização e finalidade

Este experimento avalia se a criação de variáveis derivadas e a aplicação de métodos de seleção de atributos melhoram a predição da variação dimensional longitudinal. A finalidade é testar se interações entre idade, água, cimento, DRY D1 e fibras aumentam o desempenho em relação às variáveis básicas.

2. Variável de resposta

A variável de resposta permanece `epsilon_t`, com preservação do sinal. Portanto, o experimento se concentra na predição da variação dimensional, e não na predição de magnitude absoluta.

3. Variáveis utilizadas

As variáveis básicas incluem relação a/c, consumos de cimento, água, DRY D1 e fibras, além de idade e variáveis categóricas. As variáveis derivadas criadas foram:

Variável derivada	Interpretação
<code>water_cement_ratio_check</code>	razão água/cimento recalculada pelos consumos
<code>dry_d1_per_cement</code>	proporção de DRY D1 por cimento
<code>water_dry_interaction</code>	interação entre água e DRY D1
<code>wb_dry_interaction</code>	interação entre relação a/c e DRY D1
<code>fiber_total</code>	soma das fibras metálica, macrofibra PP e microfibra PP
<code>fiber_total_per_cement</code>	proporção de fibras totais por cimento
<code>water_fiber_interaction</code>	interação entre água e fibras totais
<code>dry_fiber_interaction</code>	interação entre DRY D1 e fibras totais
<code>wb_fiber_interaction</code>	interação entre relação a/c e fibras totais
<code>water_per_fiber_plus_one</code>	razão entre água e fibras totais, com ajuste contra divisão por zero
<code>cement_water_product</code>	produto entre cimento e água
<code>cement_dry_interaction</code>	interação entre cimento e DRY D1
<code>idade_dry_interaction</code>	interação entre idade e DRY D1
<code>idade_wb_interaction</code>	interação entre idade e relação a/c
<code>idade_fiber_interaction</code>	interação entre idade e fibras totais
<code>idade_water_interaction</code>	interação entre idade e consumo de água

4. Modelos avaliados

Foram avaliados modelos com variáveis básicas, modelos com variáveis derivadas e modelos com seleção de atributos. A validação foi feita por grupo de amostra.

Tabela 23 — Comparação entre engenharia e seleção de atributos

A Tabela 23 compara todos os cenários de atributos e seleção. O RMSE é usado como critério principal de ranqueamento; MAE, R² e acurácia do sinal complementam a interpretação.

Arquivo de origem: `experimento_07_engenharia_selecao/resultados/comparacao_engenharia_selecao.csv`

MAE	RMSE	R2	acuracia_sinal	modelo	MAE_cv_medio	MAE_cv_desvio	RMSE_cv_medio	l
48.44	86.232	0.791	0.884	ExtraTrees_variaveis_basicas	48.446	5.329	85.136	
49.297	89.362	0.776	0.856	ExtraTrees_variaveis_derivadas	49.303	4.781	88.255	
63.112	92.694	0.759	0.798	ElasticNet_derivadas	63.12	6.438	91.914	
62.545	96.08	0.741	0.797	RFE15_Ridge	62.554	7.135	94.825	
63.161	96.159	0.74	0.794	Ridge_variaveis_basicas	63.167	5.998	95.09	
64.491	97.216	0.735	0.791	Lasso_derivadas	64.499	5.433	96.227	
65.116	97.466	0.733	0.784	Ridge_variaveis_derivadas	65.123	5.526	96.513	
67.091	98.4	0.728	0.789	SelectKBest15_Ridge	67.095	6.712	97.856	

6. Variáveis selecionadas pela engenharia e seleção de atributos

Tabela 24 — Variáveis selecionadas pelo SelectKBest15

O SelectKBest seleciona as variáveis com maior associação estatística individual com `epsilon_t`, usando `f_regression`.

ordem	variavel_selecionada	score_f
1	idade_water_interaction	1525.85
2	idade_wb_interaction	1489.45
3	idade_dias	1476.72
4	idade_horas	1476.72
5	idade_label_56 dias	721.666
6	dry_d1_per_cement	381.005
7	dry_d1	380.563
8	wb_dry_interaction	378.225
9	water_dry_interaction	376.774
10	cement_dry_interaction	374.151
11	idade_label_28 dias	129.674
12	idade_fiber_interaction	126.869
13	idade_label_3 dias	88.933
14	dry_fiber_interaction	83.326
15	idade_label_7 dias	82.119

Tabela 25 — Variáveis selecionadas pelo RFE15 + Ridge


O RFE seleciona variáveis de forma recursiva, considerando o comportamento do modelo Ridge. A tabela apresenta as variáveis selecionadas e o impacto absoluto dos coeficientes.

ordem	variavel_selecionada	coeficiente_ridge	impacto_absoluto
1	cement_CP II F 32	207.174	207.174
2	curing_56 dias ar 50% umidade	-190.73	190.73
3	idade_water_interaction	-164.199	164.199
4	water_fiber_interaction	130.561	130.561
5	fiber_total	-128.123	128.123
6	idade_label_56 dias	109.166	109.166

ordem	variavel_selecionada	coeficiente_ridge	impacto_absoluto
7	local_ensaio_Campo	-105.999	105.999
8	estado_ES	-95.681	95.681
9	wb_dry_interaction	83.24	83.24
10	estado_RS	63.563	63.563
11	cement_CP II Z 32	63.563	63.563
12	idade_label_7 dias	54.85	54.85
13	cement_CP II	-52.184	52.184
14	local_ensaio_Laboratório	51.488	51.488
15	local_ensaio_Não informado	50.859	50.859

Figura 5 — Comparação dos cenários de engenharia e seleção

A Figura 5 mostra o RMSE de cada cenário. Como RMSE é erro, a menor barra representa o melhor desempenho.



8. Interpretação dos resultados

O melhor desempenho foi obtido por **ExtraTrees_variaveis_basicas**, com RMSE de 86.232 µm/m, MAE de 48.440 µm/m, R² de 0.791 e acurácia do sinal de 0.884.

O resultado é tecnicamente relevante porque indica que, nesta base, a engenharia de atributos não superou o modelo Extra Trees com variáveis básicas. Isso não invalida as variáveis derivadas; mostra apenas que o modelo de árvores conseguiu capturar relações não lineares relevantes sem necessidade de aumentar a dimensionalidade.

As variáveis selecionadas pelos métodos estatísticos reforçam a importância da idade e das interações longitudinais, sobretudo **idade_water_interaction**, **idade_wb_interaction**, **idade_dias**, **idade_horas** e variáveis associadas ao DRY D1.

9. Conclusão do experimento

O Experimento 7 mostra que a engenharia de atributos e a seleção de variáveis foram metodologicamente úteis, mas não produziram o melhor desempenho global. A configuração mais forte permaneceu com Extra Trees e variáveis básicas.

Discussão teórica e justificativa metodológica

A engenharia de atributos foi adotada para testar se interações entre idade, água, cimento, DRY D1 e fibras melhoram a capacidade preditiva. Essa escolha é coerente com a literatura aplicada ao concreto, pois Hilloulin e Umnakwe (2024) destacam a influência de proporções de mistura e SCMs na predição de respostas dimensionais associadas à retração, enquanto Khajehdehi et al. (2018) discutem efeitos combinados de cura interna, SCMs e aditivos expansivos. A criação de interações como idade×DRY D1, água×fibra e DRY D1×fibra traduz computacionalmente a hipótese de que os efeitos dos materiais não são apenas aditivos.

A seleção de atributos foi incluída para avaliar se um subconjunto de variáveis mantém desempenho comparável, reduzindo complexidade. Em modelos com muitos atributos derivados, a seleção contribui para uma leitura mais estável da estrutura preditiva. Taffese et al. (2025) reforçam a importância da qualidade e interpretação dos dados em aplicações de machine learning em durabilidade do concreto, e Lundberg e Lee (2017) destacam que modelos preditivos precisam ser acompanhados de mecanismos de interpretação quando usados em contextos aplicados.

Os resultados indicam que a engenharia de atributos não produziu ganho global expressivo sobre as variáveis básicas com Extra Trees. Essa conclusão não invalida as variáveis derivadas; ela sugere que, para esta base específica, o modelo baseado em árvores já capturou parte das interações relevantes a partir dos atributos originais.

Experimento 8 — Ajuste fino do modelo

Síntese teórico-metodológica

O oitavo experimento avaliou combinações de número de atributos selecionados por RFE e valores de regularização da Ridge Regression. A intenção foi observar o equilíbrio entre desempenho, estabilidade e parcimônia. Essa abordagem dialoga com Kohavi (1995) e Arlot e Celisse (2010), que tratam a validação cruzada como mecanismo de apoio à seleção de modelos.

As métricas foram analisadas em conjunto. O MAE oferece leitura direta do erro médio em $\mu\text{m/m}$, conforme Willmott e Matsuura (2005), enquanto o RMSE evidencia desvios maiores, em consonância com Chai e Draxler (2014). O R^2 e a acurácia do sinal complementam a leitura, pois indicam, respectivamente, a proporção da variância explicada e a preservação do sentido físico da deformação.

Os resultados do ajuste fino apoiam a seleção de uma configuração final para o protótipo, mas também revelam uma tensão metodológica comum: a configuração com menor RMSE nem sempre coincide com a menor MAE ou com a melhor simplicidade operacional. Essa distinção deve ser melhor explicitada na dissertação.

Desenvolvimento detalhado do experimento

1. Caracterização e finalidade

Este experimento realiza o ajuste fino de configurações do modelo, buscando melhorar o desempenho preditivo após a comparação de modelos e atributos. A finalidade é testar combinações de hiperparâmetros e selecionar uma configuração final com base em métricas de regressão e acurácia do sinal.

2. Procedimento executado

Foram testadas diferentes configurações de seleção de atributos e regularização. Os resultados foram organizados por MAE, RMSE, R^2 , acurácia do sinal e estatísticas da validação cruzada.

Tabela 26 — Resultados do ajuste fino

A Tabela 26 apresenta as configurações avaliadas no ajuste fino. O melhor modelo deve ser identificado pelo menor RMSE, considerando também R^2 e acurácia do sinal.

Arquivo de origem: `experimento_08_ajuste_fino/resultados/ajuste_fino_resultados.csv`

MAE	RMSE	R2	acuracia_sinal	modelo	MAE_cv_medio	MAE_cv_desvio	RMSE_cv_medio	RMSE_cv_desvio	R2_cv_medio
63.103	94.235	0.751	0.798	RFE 15	63.108	5.297	93.555	11.441	
				+					
				Ridge alpha 10.0					
63.027	94.923	0.747	0.795	RFE 20	63.034	5.82	94.062	12.91	
				+					
				Ridge alpha 10.0					
64.963	95.98	0.741	0.789	RFE 10	64.967	5.491	95.353	11.092	
				+					
				Ridge					

MAE	RMSE	R2	acuracia_sinal	modelo	MAE_cv_medio	MAE_cv_desvio	RMSE_cv_medio	RMSE_cv_desvio	R
				alpha 10.0					
				RFE 15 +					
62.545	96.08	0.741	0.797	Ridge alpha 1.0	62.554	7.135	94.825	15.64	
				RFE 15 +					
63.967	96.617	0.738	0.782	Ridge alpha 0.1	63.977	8.026	95.493	14.838	
				RFE 20 +					
63.79	97.208	0.735	0.796	Ridge alpha 1.0	63.798	6.82	95.884	16.152	
				RFE 10 +					
64.573	98.154	0.729	0.782	Ridge alpha 1.0	64.583	8.23	96.892	15.845	
				RFE 20 +					
65.098	99.958	0.719	0.782	Ridge alpha 0.1	65.111	8.269	98.348	18.049	
				RFE 10 +					
86.563	123.321	0.573	0.674	Ridge alpha 0.1	86.574	12.081	122.196	16.811	

Tabela 27 — Matriz de RMSE por configuração

A Tabela 27 organiza o RMSE em formato matricial, facilitando a comparação entre número de atributos e valores de regularização.

Arquivo de origem: [experimento_08_ajuste_fino/resultados/matriz_rmse.csv](#)

n_features	0.1	1.0	10.0
10	123.321	98.154	95.98
15	96.617	96.08	94.235
20	99.958	97.208	94.923

Tabela 28 — Matriz de R² por configuração

A Tabela 28 apresenta o R² em matriz, permitindo observar como a capacidade explicativa varia entre as configurações testadas.


Arquivo de origem: [experimento_08_ajuste_fino/resultados/matriz_r2.csv](#)

n_features	0.1	1.0	10.0
10	0.573	0.729	0.741

n_features	0.1	1.0	10.0
15	0.738	0.741	0.751
20	0.719	0.735	0.747

Figura 6 — Principais configurações por RMSE

A Figura 6 apresenta as configurações com melhor desempenho por RMSE. A menor barra representa a configuração mais favorável.



5. Interpretação dos resultados

A melhor configuração pelo critério de RMSE foi **RFE 15 + Ridge alpha 10.0**, com RMSE de 94.235 $\mu\text{m/m}$, MAE de 63.103 $\mu\text{m/m}$, R^2 de 0.751 e acurácia do sinal de 0.798.

O ajuste fino permite verificar se a melhoria vem de uma configuração mais complexa ou se o ganho é marginal. Essa distinção é importante para evitar a escolha de modelos excessivamente complexos sem benefício real.

6. Conclusão do experimento

O Experimento 8 define a configuração ajustada a ser considerada na consolidação do protótipo. A escolha final deve equilibrar desempenho, estabilidade e interpretabilidade operacional.

Discussão teórica e justificativa metodológica

O ajuste fino foi realizado após a comparação de modelos e atributos, buscando avaliar o efeito do número de variáveis selecionadas e do parâmetro de regularização da Ridge Regression. A decisão de testar diferentes configurações por validação cruzada dialoga com Kohavi (1995) e Arlot e Celisse (2010), que tratam a validação cruzada como procedimento de estimativa de desempenho e seleção de modelos.

A regularização foi mantida porque a base longitudinal combina variáveis numéricas, categóricas e atributos derivados. Nesse cenário, modelos lineares regularizados podem oferecer uma solução mais estável e mais interpretável do que modelos de maior complexidade, ainda que nem sempre apresentem o menor erro absoluto possível. A escolha por RFE com diferentes números de atributos permite avaliar a tensão entre parcimônia e desempenho.

As métricas foram analisadas em conjunto. Willmott e Matsuura (2005) sustentam a leitura do MAE como erro médio diretamente interpretável, enquanto Chai e Draxler (2014) justificam a presença do RMSE para evidenciar erros maiores. Assim, o experimento não se apoia em uma métrica isolada; ele observa erro médio, penalização de grandes desvios, proporção de variância explicada e acurácia do sinal.

Experimento 9 — Protótipo preditivo longitudinal

Síntese teórico-metodológica

O nono experimento consolidou o sistema preditivo. O modelo final foi salvo como artefato `.joblib`, e foi gerado um exemplo de previsão de curva para novas entradas. Essa etapa converte a análise experimental em um protótipo operacional capaz de estimar a variação dimensional em múltiplas idades.

A decisão de manter `epsilon_t` como saída principal preserva o sentido físico da variável estudada. O protótipo não prediz apenas a magnitude absoluta da retração; ele estima a variação dimensional com sinal e classifica o comportamento como retração, expansão ou estabilidade. Essa formulação dialoga com os trabalhos que tratam a retração como resposta dependente de composição, idade e condições experimentais (Hilloulin e Umunnakwe, 2024; Hilloulin e Tran, 2023; Ocak et al., 2024; Qureshi et al., 2022).

A inclusão de faixas aproximadas de erro, erro mediano e percentis de erro contribui para comunicar a incerteza do protótipo. A previsão é apresentada como estimativa experimental, não como valor determinístico. Essa leitura está em consonância com a literatura de métricas de erro e avaliação de modelos (Willmott e Matsuura, 2005; Chai e Draxler, 2014).

Um ponto de atenção permanece na transição entre os Experimentos 8 e 9: o Experimento 8 indicou menor RMSE para `RFE 15 + Ridge alpha 10.0`, enquanto o Experimento 9 utiliza `RFE 15 + Ridge alpha 1.0`. **Essa diferença pode ser tratada de duas formas no texto: como escolha por equilíbrio entre MAE, simplicidade e desempenho do sinal, ou por ajuste do script final para adotar a configuração de menor RMSE. A decisão precisa ser explicitada para evitar ambiguidade metodológica.**

Síntese da contribuição metodológica para a dissertação

A sequência dos nove experimentos operacionaliza o eixo computacional da dissertação. A base física está na variação dimensional de concretos com fibras e aditivos; a base metodológica está na transformação longitudinal, validação agrupada, comparação de modelos, análise de erros e consolidação de protótipo. A contribuição esperada não é apenas escolher o melhor algoritmo, mas estruturar um procedimento rastreável para estimar a deformação dimensional em função da idade e das características do traço.

Desenvolvimento detalhado do experimento

1. Caracterização e finalidade

Este experimento consolida o sistema preditivo longitudinal. A finalidade é transformar a modelagem desenvolvida na sequência experimental em um protótipo operacional capaz de estimar a curva de variação dimensional para novos traços.

Este experimento não tem apenas função comparativa; ele organiza o modelo final, avalia seu desempenho, salva o artefato treinado e gera exemplo de predição por idade.

2. Variável de resposta e saída operacional

A saída principal é `epsilon_t`, isto é, a variação dimensional prevista para cada idade. O protótipo também classifica o sinal previsto como retração, expansão ou estabilidade e calcula faixas aproximadas de erro.

3. Procedimento executado

O modelo final foi avaliado por validação cruzada agrupada, com cálculo de métricas globais, resíduos, erro absoluto, acurácia do sinal e percentis de erro. Em seguida, o modelo foi treinado na base completa e salvo como arquivo `.joblib`.

Tabela 29 — Métricas do protótipo longitudinal

A Tabela 29 apresenta as métricas finais do protótipo: MAE, RMSE, R², acurácia do sinal, erro mediano absoluto e percentis 75 e 90 do erro. Os percentis permitem comunicar uma faixa aproximada de incerteza.

Arquivo de origem: `experimento_09_prototipo_longitudinal/resultados/metricas_prototipo_longitudinal.csv`

MAE	RMSE	R2	acuracia_sinal	erro_mediano_absoluto	erro_percentil_75	erro_percentil_90
62.545	96.08	0.741	0.797	42.615	76.135	123.4

Tabela 30 — Avaliação do protótipo por registro

A Tabela 30 apresenta a avaliação fora da amostra para cada registro longitudinal. Ela contém valor real, valor previsto, resíduo, erro absoluto e sinal real e previsto. É a tabela principal para auditoria do desempenho do protótipo.

Arquivo de origem: `experimento_09_prototipo_longitudinal/resultados/avaliacao_prototipo_longitudinal.csv`

A tabela completa possui **1447 registros e 9 colunas**. Para manter a leitura viável, apresenta-se abaixo uma visualização parcial, mantendo o arquivo CSV completo na pasta de resultados.

amostra_id	idade_label	idade_dias	epsilon_t	epsilon_previsto	residuo	erro_absoluto	sinal_real	sinal_previsto
0	12 h	0.5	0	61.124	-61.124	61.124	estabilidade	expansao
138	12 h	0.5	0	-85.677	85.677	85.677	estabilidade	retracao
41	12 h	0.5	0	55.069	-55.069	55.069	estabilidade	expansao
139	12 h	0.5	0	115.351	-115.351	115.351	estabilidade	expansao
140	12 h	0.5	0	-83.261	83.261	83.261	estabilidade	retracao
40	12 h	0.5	0	115.351	-115.351	115.351	estabilidade	expansao
141	12 h	0.5	0	52.533	-52.533	52.533	estabilidade	expansao
137	12 h	0.5	0	29.193	-29.193	29.193	estabilidade	expansao
39	12 h	0.5	0	-85.882	85.882	85.882	estabilidade	retracao
143	12 h	0.5	0	43.6	-43.6	43.6	estabilidade	expansao
38	12 h	0.5	0	76.289	-76.289	76.289	estabilidade	expansao
144	12 h	0.5	0	-85.709	85.709	85.709	estabilidade	retracao
145	12 h	0.5	0	96.06	-96.06	96.06	estabilidade	expansao
37	12 h	0.5	0	-69.316	69.316	69.316	estabilidade	retracao
146	12 h	0.5	0	-83.859	83.859	83.859	estabilidade	retracao
142	12 h	0.5	0	-69.348	69.348	69.348	estabilidade	retracao
42	12 h	0.5	0	-85.564	85.564	85.564	estabilidade	retracao
136	12 h	0.5	0	-69.015	69.015	69.015	estabilidade	retracao
43	12 h	0.5	0	62.53	-62.53	62.53	estabilidade	expansao
126	12 h	0.5	0	-85.859	85.859	85.859	estabilidade	retracao
48	12 h	0.5	0	-80.262	80.262	80.262	estabilidade	retracao
127	12 h	0.5	0	56.668	-56.668	56.668	estabilidade	expansao
128	12 h	0.5	0	-86.498	86.498	86.498	estabilidade	retracao
47	12 h	0.5	0	68.067	-68.067	68.067	estabilidade	expansao
129	12 h	0.5	0	106.056	-106.056	106.056	estabilidade	expansao
106	56 dias	56	-430	-444.462	14.462	14.462	retracao	retracao
59	56 dias	56	-460	-433.128	-26.872	26.872	retracao	retracao
168	56 dias	56	-390	-461.631	71.631	71.631	retracao	retracao
22	56 dias	56	-590	-465.703	-124.297	124.297	retracao	retracao
107	56 dias	56	-360	-369.698	9.698	9.698	retracao	retracao
58	56 dias	56	-320	-340.893	20.893	20.893	retracao	retracao
167	56 dias	56	-260	-254.481	-5.519	5.519	retracao	retracao
108	56 dias	56	-290	-270.28	-19.72	19.72	retracao	retracao
27	56 dias	56	-350	-282.06	-67.94	67.94	retracao	retracao
38	56 dias	56	-350	-285.742	-64.258	64.258	retracao	retracao

Observação: o CSV completo correspondente permanece disponível na pasta de resultados do experimento.

Tabela 31 — Exemplo de predição de curva para novo traço


A Tabela 31 apresenta um exemplo de saída operacional do protótipo. Para cada idade, são fornecidos o valor previsto de `epsilon_t`, o sinal previsto e a faixa aproximada baseada no MAE.

Arquivo de origem: `experimento_09_prototipo_longitudinal/resultados/exemplo_predicao_curva.csv`

idade_label	idade_dias	epsilon_t_previsto	sinal_previsto	faixa_mae_min	faixa_mae_max
12 h	0.5	49.676	expansao	-12.869	112.221
1 dia	1	45.209	expansao	-17.336	107.754
3 dias	3	27.341	expansao	-35.204	89.886
7 dias	7	46.455	expansao	-16.09	109
14 dias	14	-70.933	retracao	-133.478	-8.388
28 dias	28	-196.009	retracao	-258.554	-133.464
56 dias	56	-336.995	retracao	-399.54	-274.45

Figura 6 — Exemplo de curva prevista

A Figura 6 representa graficamente a curva prevista de variação dimensional para um novo traço. Essa figura demonstra a passagem do modelo estatístico para uma saída interpretável no formato de curva temporal.



6. Interpretação dos resultados

O Experimento 9 demonstra que a sequência experimental pode ser convertida em um protótipo de uso prático. O modelo passa a retornar uma previsão por idade, e não apenas um número isolado. Essa estrutura é compatível com a predição da variação dimensional ao longo do tempo.

A acurácia do sinal indica se o protótipo acerta o sentido físico da deformação. As métricas MAE e RMSE indicam o erro de magnitude. Os percentis de erro ajudam a comunicar incerteza de forma mais prudente.

7. Limitação objetiva

Neste experimento foram calculadas métricas de regressão e acurácia do sinal, mas não foram geradas matriz de confusão, precision, recall e F1 por classe. Esses indicadores podem ser acrescentados em uma versão posterior caso se deseje aprofundar a avaliação categórica entre retração, expansão e estabilidade.

8. Conclusão do experimento

O Experimento 9 consolida o sistema preditivo longitudinal. O resultado final é um protótipo capaz de estimar a variação dimensional com sinal em diferentes idades, preservando a interpretação física entre retração, expansão e estabilidade.

Discussão teórica e justificativa metodológica

O protótipo longitudinal consolida a sequência experimental ao transformar o modelo em artefato reutilizável para novas entradas. Essa etapa é coerente com os estudos aplicados de machine learning à variação dimensional e a fenômenos associados à retração, como Hilloulin e Ummunnakwe (2024), Hilloulin e Tran (2023), Ocak et al. (2024) e Qureshi et al. (2022), nos quais a predição depende da combinação entre composição do material, idade e condições do ensaio.

A saída operacional foi mantida como `epsilon_t` com sinal, acompanhada da classificação em retração, expansão ou estabilidade. Essa decisão preserva a interpretação física adotada na sequência experimental. A inclusão de faixa aproximada de erro baseada no MAE e em percentis do erro oferece uma forma de comunicar incerteza sem transformar o protótipo em ferramenta determinística. Essa leitura dialoga com Willmott e Matsuura (2005) e Chai e Draxler (2014), pois as métricas de erro são tratadas como medidas de desempenho e como apoio à interpretação prática das previsões.

A validação agrupada permanece relevante no protótipo, pois a avaliação precisa representar a capacidade de generalização para amostras não vistas. Kaufman et al. (2012) sustentam essa cautela ao discutir vazamento em mineração de dados. Lundberg e Lee (2017), por sua vez, reforçam a importância da interpretação de modelos complexos e de seus resultados; por isso, mesmo quando o protótipo gera previsões, sua leitura permanece vinculada aos limites da base experimental.

Ponto de atenção metodológico

O Experimento 8 indicou menor RMSE para a configuração `RFE 15 + Ridge alpha 10.0`, enquanto o script do Experimento 9 consolida o protótipo com `RFE 15 + Ridge alpha 1.0`. Essa diferença não impede a apresentação do protótipo, mas convém explicitar no texto que a configuração final foi escolhida pelo equilíbrio entre erro médio, simplicidade operacional e desempenho do sinal, ou então ajustar o script do Experimento 9 para usar exatamente a configuração de menor RMSE indicada no Experimento 8. Essa observação é metodológica, não conceitual.

Referências

- ARLOT, S.; CELISSE, A. A survey of cross-validation procedures for model selection. *Statistics Surveys*, 2010.
- BREIMAN, L. Random Forests. *Machine Learning*, 2001.
- CHAI, T.; DRAXLER, R. R. Root mean square error (RMSE) or mean absolute error (MAE)? Arguments against avoiding RMSE in the literature. *Geoscientific Model Development*, 2014.
- FOLORUNSHO, A. B. et al. A Review on the Performance of Fibers on Restrained Plastic Shrinkage Cracks in Concrete. *Buildings*, 2024.
- FRIEDMAN, J. H. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 2001.
- GEURTS, P.; ERNST, D.; WEHENKEL, L. Extremely randomized trees. *Machine Learning*, 2006.
- HILLOULIN, B.; TRAN, V. Q. Interpretable machine learning model for autogenous shrinkage prediction of low-carbon cementitious materials. *Construction and Building Materials*, 2023.
- HILLOULIN, B.; UMUNNAKWE, R. Machine learning-aided prediction of shrinkage in modern concrete: Focus on mix proportions and SCMs. *Journal of Building Engineering*, 2024.
- KAUFMAN, S.; ROSSET, S.; PERLICH, C.; STITELMAN, O. Leakage in Data Mining: Formulation, Detection, and Avoidance. *ACM Transactions on Knowledge Discovery from Data*, 2012.
- KHAJEHDEHI, R.; FENG, M.; DARWIN, D.; LAFIKES, J.; IBRAHIM, E. K.; O'REILLY, M. Combined Effects of Internal Curing, SCMs, and Expansive Additives on Concrete Shrinkage. *Advances in Civil Engineering Materials*, 2018.
- KOHAVI, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. *IJCAI*, 1995.
- LUNDBERG, S. M.; LEE, S.-I. A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems*, 2017.
- OCAK, A.; BEKDAŞ, G.; İŞIKDAĞ, Ü.; NIGDELI, S. M.; BILIR, T. Drying shrinkage and crack width prediction using machine learning in mortars containing different types of industrial by-product fine aggregates. *Journal of Building Engineering*, 2024.
- POWERS, D. M. W. Evaluation: From Precision, Recall and F-Measure to ROC, Informedness, Markedness and Correlation. *Journal of Machine Learning Technologies*, 2011.
- QURESHI, H. J. et al. Prediction of Autogenous Shrinkage of Concrete Incorporating Super Absorbent Polymer and Waste Materials through Individual and Ensemble Machine Learning Approaches. *Materials*, 2022.
- SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 2009.

- STATKAUSKAS, M.; GRINYS, A.; VAIČIUKYNIENĖ, D. Investigation of Concrete Shrinkage Reducing Additives. Materials, 2022.
- TAFSESE, W. Z. et al. Machine learning in concrete durability: challenges and pathways identified by RILEM TC 315-DCS towards enhanced predictive models. Materials and Structures, 2025.
- WILLMOTT, C. J.; MATSUURA, K. Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance. Climate Research, 2005.